Panduan Pengujian di Lab Pengujian

Panduan ini mengikuti proposal revisi dosbim 2 (`Proposal_PA_Syafii_revisi-dosbim2.docx`): 3 tugas × 20 dokumen, Layer 1 tiga lapis, Layer 2 Gemini `gemini-3.5-flash-lite`, pemilihan threshold dengan 5-fold cross-validation, dan uji konsistensi deteksi AI. Versi cetaknya ada di `Panduan-Pengujian.pdf`.

Di aplikasi, setiap bagian hasil punya tombol **"Penjelasan: apa ini dan cara membacanya"**, dan setiap halaman punya panel **"Istilah dan cara membaca nilai"**. Bagian 1 di bawah adalah ringkasan isi keduanya.

---

1. Memahami judul dan istilah dulu

1.1 Judul dalam bahasa sederhana

> *Analisis Efektivitas Metode Multi-Layer Semantic Vector Embedding dan LLM dalam Deteksi Kemiripan Teks serta Konten AI-Generated*

Bagian judul	Artinya
Deteksi kemiripan teks	Mencari pasangan tugas mahasiswa yang saling menyalin, baik salin langsung (verbatim) maupun diubah kata-katanya (parafrase).
Konten AI-generated	Tugas yang seluruhnya dibuat oleh AI (ChatGPT).
Semantic Vector Embedding	Teks diubah menjadi deretan angka (vektor) yang mewakili **makna**. Dua kalimat bermakna sama punya vektor yang berdekatan walaupun kata-katanya berbeda.
LLM	Model bahasa besar (di sini Gemini) yang bisa membaca dua teks lalu menjelaskan bagian mana yang disalin. Pintar tetapi lambat dan dibatasi kuota.
Multi-Layer	Dua tahap. **Layer 1** (embedding) menyaring semua pasangan dengan cepat dan gratis. Hanya pasangan yang mencurigakan diteruskan ke **Layer 2** (LLM).
Analisis efektivitas	Diukur dari dua sisi pada threshold yang sama: **akurasi** (precision, recall, F1) dan **efisiensi** (berapa panggilan LLM yang dihemat).

Perumpamaan: Layer 1 adalah **satpam di gerbang** yang memeriksa semua orang sekilas, sedangkan Layer 2 adalah **penyidik** yang hanya memeriksa orang yang dicurigai satpam. Penyidik mahal, jadi makin sedikit yang dikirim makin hemat. Tetapi kalau satpam terlalu longgar, penjahat lolos dan penyidik tidak pernah melihatnya.

1.2 Tiga rumusan masalah dan di mana jawabannya

RM	Pertanyaan sederhana	Dijawab di aplikasi
RM 1	Seberapa akurat sistem menemukan pasangan yang menyalin? Apakah Layer 2 menambah akurasi?	Evaluasi gabungan → "Hasil per tugas dan gabungan", "Pemilihan ambang dan bobot lapis"; halaman run → "Deteksi per jenis plagiat"

RM	Pertanyaan sederhana	Dijawab di aplikasi
RM 2	Berapa banyak panggilan LLM yang bisa dihemat Layer 1, dan berapa harganya (plagiat yang terlewat)?	Evaluasi gabungan → "Efisiensi pemanggilan LLM", "F1 terhadap ambang (gabungan)"
RM 3	Seberapa andal LLM membedakan tulisan manusia dan AI? Apakah penilaiannya konsisten?	Evaluasi gabungan → "Deteksi konten AI (gabungan)", "Uji konsistensi deteksi AI (gabungan)"

1.3 Empat kemungkinan hasil (dasar semua metrik)

Setiap pasangan dokumen punya **label** (kunci jawaban: plagiat atau bukan) dan **prediksi** sistem.

	Sistem: plagiat	**Sistem: bukan**
Label: plagiat	**TP** – benar menangkap	**FN** – plagiat terlewat
Label: bukan	**FP** – salah tuduh	**TN** – benar dibiarkan

Di aplikasi, kotak ini disebut *confusion matrix*: hijau = TP, merah = FN, kuning = FP, abu-abu = TN.

1.4 Kamus metrik

Metrik	Rumus	Artinya	Rentang	Yang baik
Precision	TP / (TP + FP)	Dari yang ditandai sistem, berapa yang benar	0–1	Besar (jarang salah tuduh)
Recall	TP / (TP + FN)	Dari yang memang plagiat, berapa yang tertangkap	0–1	Besar (jarang terlewat)
F1-score	2·P·R / (P + R)	Gabungan precision dan recall; hanya tinggi bila keduanya tinggi. **Metrik utama.**	0–1	Besar
Akurasi	(TP + TN) / semua	Persentase keputusan benar	0–1	Besar, tetapi **bisa menipu** (lihat bawah)
Reduction rate	(1 − diteruskan / semua) × 100%	Persentase panggilan LLM yang dihemat	0–100%	Besar, asal recall tetap tinggi
Simpangan baku (sd)	sebaran nilai dari rata-ratanya	Seberapa stabil/konsisten	≥ 0	Kecil
ai_probability	penilaian LLM	Seberapa mungkin dokumen ditulis AI (bukan peluang yang terkalibrasi)	0–1	Rendah untuk tulisan manusia, tinggi untuk Full AI

Kenapa akurasi menipu: dari 190 pasangan per tugas, hanya 15 yang plagiat. Sistem yang tidak menandai apa pun tetap benar 175/190 = **92%**, padahal tidak menangkap satu pun plagiat (recall 0, F1 0). Karena itu yang diutamakan F1.

Contoh hitung: sistem menandai 18 pasangan; 14 benar plagiat (TP = 14), 4 salah tuduh (FP = 4), dan 1 plagiat terlewat (FN = 1). Precision = 14/18 = 0,78 · Recall = 14/15 = 0,93 · F1 = 2 × 0,78 × 0,93 / (0,78 + 0,93) = 0,85.

1.5 Istilah khusus sistem ini

Istilah	Penjelasan
Pasangan	Setiap dokumen dibandingkan dengan setiap dokumen lain di tugas yang sama: N(N−1)/2. 20 dokumen → **190 pasangan**.
Label otomatis	Dua dokumen = plagiat bila berasal dari dokumen original yang sama (O1–V1, O1–P1, V1–P1). 5 keluarga × 3 = **15 pasangan plagiat** per tugas.
Skor D / P / K	Skor Layer 1 per lapis, 0–1. **D** (dokumen) = kesamaan topik. **P** (passage ±60 kata) = kesamaan gagasan, mengenali parafrase. **K** (kalimat) = proporsi kalimat hampir identik (cosine ≥ 0,85), mengenali salinan.
Skor gabungan	0,2·D + 0,4·P + 0,4·K (Persamaan 3.2). Dibandingkan dengan threshold.
Threshold (ambang)	Skor gabungan ≥ threshold → diteruskan ke LLM. Rendah = teliti tetapi boros; tinggi = hemat tetapi berisiko melewatkan plagiat.
Tahap 1 / Tahap 2	Nama lain Layer 1 / Layer 2 di aplikasi. "Tahap 1 + 2" = pasangan dianggap plagiat bila lolos threshold **dan** dikonfirmasi LLM.
5-fold cross-validation (CV)	Data dibagi 5 bagian. Bergantian, 4 bagian dipakai **memilih** threshold terbaik dan 1 bagian dipakai **menilai**. Hasilnya lebih jujur daripada memilih dan menilai di data yang sama.
F1 CV ± sd	Rata-rata F1 dari 5 kali penilaian ± sebarannya. sd kecil = stabil.
Ambang per fold	Threshold yang terpilih di setiap putaran CV. Kalau nilainya sama atau berdekatan, pilihan threshold bisa dipercaya.
Ablation	Membandingkan versi sistem dengan bagian yang dilepas/diubah (hanya lapis D, hanya P, hanya K, bobot berbeda) untuk melihat kontribusi tiap bagian.
Verdict AI	Kemungkinan AI (≥ 0,70), Campuran (0,35–0,69), Ditulis manusia (< 0,35). Keputusan penelitian memakai **≥ 0,50 = AI**.
Uji konsistensi	Dokumen yang sama dinilai LLM beberapa kali. Kalau skornya berubah-ubah, hasil deteksi kurang dapat dipercaya.

---

2. Persiapan

2.1 Sistem

1. Jalankan Docker Desktop, lalu di folder `similarity-system`: `docker compose up -d`.
2. Pastikan `.env` berisi: `GEMINI_MODELS=gemini-3.5-flash-lite GEMINI_DELAY_SECONDS=4` Setelah mengubah `.env`: `docker compose up -d fastapi`.
3. Buka `http://localhost:8081`, masuk dengan akun **peneliti** (`peneliti@kampus.ac.id` / `password`).

2.2 Kuota Gemini (akun gratis, Flash Lite)

15 permintaan/menit, **500 permintaan/hari** (direset sekitar pukul 14.00–15.00 WIB). Perkiraan kebutuhan seluruh pengujian ±300–400 panggilan, jadi cukup dalam 1 hari, lebih aman dibagi 2 hari (lihat Bagian 4).

2.3 Dokumen per tugas (20 dokumen)

Kategori proposal	Kode	Jumlah	Kategori di aplikasi (CSV)	Sumber
Original	T1-O1 … T1-O5	5	`asli`	–
Verbatim	T1-V1 … T1-V5	5	`salinan langsung`	original pasangannya
Parafrase	T1-P1 … T1-P5	5	`parafrase manual`	original pasangannya
Full AI	T1-AI1 … T1-AI5	5	`full ai`	–

Gunakan versi **Potongan** dari folder `Dataset/2/Tema N/Potongan/` sebagai dokumen original (DOCX).

---

3. Langkah pengujian

Langkah 1 – Buat tiga dataset (satu per tugas)

1. Lab Pengujian → **Buat dataset**: `Tugas 1 – Pembelajaran daring`, `Tugas 2 – Pemasaran digital UMKM`, `Tugas 3 – Sampah plastik`.
2. Buka dataset → panel **Impor massal** → unduh templat CSV.
3. Isi manifest (pemisah `;`), contoh Tugas 1: `berkas;judul;kategori;sumber;teks T1-O1.docx;T1-O1;asli;; T1-V1.docx;T1-V1;salinan langsung;T1-O1.docx; T1-P1.docx;T1-P1;parafrase manual;T1-O1.docx; T1-AI1.docx;T1-AI1;full ai;; ...`
4. Pilih ke-20 berkas + manifest → Impor. Kalau ada kesalahan, tidak ada yang tersimpan dan setiap baris yang salah ditampilkan.
5. **Cek:** dataset berisi 20 dokumen; setiap Verbatim/Parafrase menunjuk original yang benar (kalau salah, label pasangan ikut salah).

Langkah 2 – Run Layer 1 saja (gratis, tanpa LLM)

Untuk **setiap** dataset → **Jalankan eksperimen**:

Isian	Nilai
Nama	`T1 – Layer 1` (T2, T3 menyesuaikan)
Ambang	0,70
Bobot D/P/K	0,2 / 0,4 / 0,4
Panjang passage	60
Ambang kalimat	0,85
Jalankan Tahap 2 (LLM) untuk pasangan di atas ambang	**tidak dicentang**
Jalankan deteksi AI per dokumen	**tidak dicentang**

Selesai dalam hitungan detik. **Cek di halaman run:** Pasangan = 190, Plagiat (label) = 15, tidak ada peringatan dokumen gagal diekstrak.

Langkah 3 – Pilih threshold dengan evaluasi gabungan

1. Menu **Evaluasi gabungan** → centang ketiga run "Layer 1" → **Gabungkan**.

2. Lihat tabel **"Pemilihan ambang dan bobot lapis (5-fold CV gabungan)"**: - baris **"Bobot run (0,2 / 0,4 / 0,4)"** → kolom *Bobot D/P/K · ambang terbaik* = **threshold terpilih**; - kolom *Ambang per fold* → catat kelima nilainya (bukti stabilitas); - bandingkan *F1 CV* semua baris → lapis mana yang paling berkontribusi.
3. **Keputusan bobot:** tetap pakai bobot awal 0,2/0,4/0,4 kecuali "Bobot hasil optimasi" jauh lebih baik (misalnya selisih F1 CV > 0,05 dan sd tidak lebih besar). Kalau ganti bobot, catat alasannya untuk Bab 4.
4. Lihat **"F1 terhadap ambang (gabungan)"** → buka tabel data → ini bahan grafik trade-off threshold vs recall vs reduction rate (RM 2).

Langkah 4 – Run lengkap dengan LLM

Untuk setiap dataset, jalankan run baru:

Isian	Nilai
Nama	`T1 – Lengkap (ambang X)`
Ambang	**threshold terpilih** dari Langkah 3
Bobot, passage, ambang kalimat	sama seperti Langkah 2 (atau bobot terpilih)
Jalankan Tahap 2 (LLM) untuk pasangan di atas ambang	**dicentang**
Jalankan deteksi AI per dokumen	**dicentang**

Jumlah panggilan per tugas ≈ pasangan di atas ambang + 20 deteksi AI. Halaman run memperbarui diri sendiri. **Cek:** tidak ada kotak merah "Sebagian panggilan LLM gagal". Kalau ada (biasanya kuota habis), hapus run lalu ulangi besok.

Langkah 5 – Run pembanding di threshold 0,70 (bila threshold terpilih ≠ 0,70)

Sama seperti Langkah 4 tetapi ambang **0,70** dan **"Jalankan deteksi AI per dokumen" tidak dicentang** (deteksi AI tidak dipengaruhi threshold, cukup sekali di Langkah 4). Ini untuk membandingkan threshold terpilih dengan threshold awal dari Syuja'i dkk.

Langkah 6 – Uji konsistensi deteksi AI

Di halaman setiap run **Lengkap** → bagian **Uji konsistensi deteksi AI**: 1. Jumlah penilaian per dokumen: **3× (run + 2 ulangan)**. 2. Jangan centang dokumen apa pun (= semua 20 dokumen) → **Mulai uji konsistensi**. 3. 40 panggilan per tugas, ±3–5 menit. Kalau terhenti karena kuota, klik **Lanjutkan uji konsistensi** besoknya; yang sudah berhasil tidak diulang. 4. **Cek:** tidak ada peringatan "Model LLM ulangan berbeda dengan model run".

Langkah 7 – Ambil hasil akhir

Evaluasi gabungan → centang ketiga run **Lengkap** → Gabungkan. Ulangi untuk ketiga run pembanding 0,70. Unduh CSV setiap run (tombol *Unduh CSV*) sebagai arsip data mentah.

---

4. Jadwal yang disarankan (kuota 500/hari)

Hari	Kegiatan	Panggilan LLM (perkiraan)
1	Langkah 1–3 (impor, run Layer 1, pilih threshold)	0
1	Langkah 4 untuk 3 tugas	±3 × (20–40 + 20) = 120–180
1	Langkah 5 untuk 3 tugas	±3 × 20–40 = 60–120
2	Langkah 6 untuk 3 tugas	3 × 40 = 120
2	Langkah 7 + tulis tabel Bab 4	0

5. Cara membaca setiap bagian dan apa yang dilaporkan

Halaman Evaluasi gabungan (hasil akhir)

Bagian	Menjawab	Yang dicatat untuk Bab 4	Hasil yang baik
Hasil per tugas dan gabungan	RM 1	P, R, F1 Layer 1 dan Layer 1+2 per tugas + gabungan; dua confusion matrix	F1 tinggi; Layer 1+2 menurunkan FP dibanding Layer 1 tanpa menambah banyak FN
Efisiensi pemanggilan LLM	RM 2	Pasangan diteruskan, reduction rate, total panggilan (verifikasi + deteksi AI), token, waktu	Reduction rate tinggi dengan recall tetap tinggi
Pemilihan ambang dan bobot lapis (CV)	RM 1, RM 2	F1 CV ± sd setiap konfigurasi, ambang per fold, threshold terpilih	F1 CV tinggi, sd kecil, ambang per fold berdekatan
F1 terhadap ambang (gabungan)	RM 1, RM 2	Tabel ambang vs P, R, F1, reduction rate → grafik trade-off	Ada rentang ambang dengan recall tinggi sekaligus reduction rate tinggi
Deteksi konten AI (gabungan)	RM 3	Confusion matrix ambang 0,50; rata-rata probabilitas per kategori; tabel ambang lain	Precision tinggi (jarang menuduh manusia); Full AI berprobabilitas tinggi, kategori lain rendah
Uji konsistensi (gabungan)	RM 3	Rata-rata sd, rentang terbesar, % keputusan tidak berubah, F1 tiap ulangan ± sd	sd kecil, keputusan tidak berubah mendekati 100%

Halaman run (detail per tugas)

Bagian	Gunanya
Ringkasan	Cek cepat: 190 pasangan, 15 plagiat, berapa diteruskan, total panggilan LLM
Ablation	Sama dengan CV gabungan tetapi hanya satu tugas (3 plagiat per fold, kurang stabil) – pakai versi gabungan untuk laporan
Deteksi per jenis plagiat	Bahan pembahasan: verbatim vs parafrase mana yang lebih sering terlewat, berapa salah tuduh
Tahap 1 vs Tahap 1+2	Kontribusi LLM pada satu tugas
F1 terhadap ambang	Pola per lapis pada satu tugas

Bagian	Gunanya
Coba bobot & ambang lain	Alat eksplorasi; **jangan** dilaporkan sebagai hasil akhir
Deteksi konten AI	Detail per tugas; ketat (≥ 0,70) vs longgar (≥ 0,35)
Uji konsistensi	Tempat menjalankan ulangan + tabel skor tiap dokumen
Semua pasangan	Mencari contoh kasus salah tuduh/terlewat untuk dibahas

Pola hasil yang mungkin muncul dan artinya

Pola	Arti	Kalimat pembahasan
F1 "lapis passage saja" ≈ gabungan	Lapis passage paling menentukan	"Lapis passage memberikan kontribusi terbesar karena mampu mengenali parafrase."
F1 "lapis dokumen saja" rendah, precision rendah	Kesamaan topik membuat banyak salah tuduh	"Lapis dokumen saja tidak cukup karena seluruh dokumen dalam satu tugas membahas topik yang sama."
Verbatim 100% tertangkap, parafrase lebih rendah	Parafrase memang lebih sulit	"Recall pada pasangan parafrase lebih rendah dibandingkan verbatim."
Layer 1+2: FP turun, FN sama	LLM berhasil menyaring salah tuduh	"Layer 2 meningkatkan precision dari … menjadi … tanpa menurunkan recall."
Parafrase manusia berprobabilitas AI tinggi	LLM keliru menganggap tulisan formal sebagai AI	Bahas sebagai keterbatasan stilometri berbasis LLM (batasan no. 12).
sd konsistensi besar / keputusan sering berubah	Penilaian LLM tidak stabil	"Hasil deteksi AI belum dapat diandalkan sebagai keputusan tunggal."

---

6. Kesalahan yang harus dihindari

1. **Melaporkan F1 "terbaik data penuh" atau hasil "Coba bobot"** sebagai hasil akhir – terlalu optimis. Laporkan F1 CV.
2. **Menggabungkan run dengan parameter berbeda** – halaman gabungan akan menampilkan peringatan kuning; samakan dulu.
3. **Mencampur model LLM** – semua run dan ulangan harus memakai `gemini-3.5-flash-lite`.
4. **Memakai run yang ada panggilan LLM gagal** – hapus dan ulangi.
5. **Salah menunjuk sumber** Verbatim/Parafrase saat impor – label pasangan jadi salah.
6. **Memasukkan dua run dari dataset yang sama** ke evaluasi gabungan – pasangan terhitung ganda.

7. Untuk demo sidang

- Semua hasil tersimpan; cukup buka **Evaluasi gabungan** dan halaman run.
- Demo langsung yang cepat:
- **Uji cepat dua teks**: tempel dua paragraf → skor D/P/K + hasil LLM (beberapa detik).
- **Uji konsistensi** pada 2–3 dokumen yang dicentang (±10 detik).
- **Coba bobot & ambang lain** dan **Coba ambang probabilitas** dihitung seketika tanpa LLM.
- Buka tombol **Penjelasan** di setiap bagian bila penguji menanyakan arti sebuah angka.