PANDUAN UJI COBA METODE

Menguji Multi-Layer Semantic Vector Embedding dan LLM dengan Lab Pengujian

Dijelaskan dengan bahasa sederhana dan perumpamaan sehari-hari: menyiapkan korpus, memilih ambang batas, ambang kalimat, bobot lapis, dan panjang passage, sampai membaca hasil (precision, recall, F1, dan lainnya) untuk Bab Hasil.

Sistem	Similarity System, Laravel + FastAPI
Menu	Lab Pengujian (akun peneliti)
Untuk	Proyek Akhir D4 Rekayasa Perangkat Lunak
Versi	Oktober 2026 · edisi bahasa sederhana

Daftar Isi

1. Sebelum Mulai: Satu Cerita untuk Semua Istilah 4

1.1 Cerita pengawas ujian 4

1.2 Apa yang sebenarnya ingin kita ketahui? 4

1.3 Alur pengujian secara singkat 5

2. Cara Sistem Membandingkan Dua Tulisan 5

2.1 Embedding: memberi "alamat" pada makna 5

2.2 Kenapa teks harus dipotong-potong? 6

2.3 D, P, dan K: tiga cara membandingkan 6

2.4 Bobot lapis: porsi tiap cara dalam nilai akhir 7

2.5 Ambang batas: nilai batas kecurigaan 7

2.6 Ambang kalimat: seberapa mirip baru dianggap "kembar" 8

2.7 Panjang passage: ukuran "paragraf mini" 8

2.8 Pengawas kedua (LLM) dan deteksi tulisan AI 9

3. Membaca Nilai Hasil: Precision, Recall, F1, dan Lainnya 9

3.1 Empat kemungkinan hasil 9

3.2 Precision: "Kalau menunjuk, seberapa sering benar?" 9

3.3 Recall: "Dari semua yang mencontek, berapa yang ketahuan?" 10

3.4 Kenapa harus melihat keduanya? 10

3.5 F1: satu nilai untuk merangkum keduanya 10

3.6 Akurasi: hati-hati, bisa menipu 10

3.7 Ringkasan semua ukuran 11

3.8 Pengawas pertama dan kedua: mana yang paling penting? 11

3.9 Cross-validation dan "± sd": menguji berkali-kali 11

3.10 Tabel "deteksi per jenis plagiat" 12

3.11 Penghematan LLM 12

3.12 Deteksi AI: ketat dan longgar 13

4. Menyiapkan "Bank Soal" (Korpus Uji) 13

4.1 Jenis tulisan dan cara membuatnya 14

4.2 Berapa banyak yang dibutuhkan? 14

4.3 Dua dataset: latihan dan ujian sungguhan 14

4.4 Etika dan catatan 15

5. Langkah Uji Coba dari Awal 15

5.1 Langkah 0: Cek sistem 15

5.2 Langkah 1: Uji awal (baseline) . . . 15
5.3 Langkah 2: Mencoba panjang passage . . . 15
5.4 Langkah 3: Mencoba ambang kalimat . . . 16
5.5 Langkah 4: Memilih bobot lapis . . . 16
5.6 Langkah 5: Memilih ambang batas . . . 16
5.7 Langkah 6: Uji lengkap . . . 17
5.8 Langkah 7: Ujian sungguhan (uji akhir) . . . 17
5.9 Langkah 8 (opsional): Membandingkan Claude dan Gemini . . . 17
5.10 Lembar catatan percobaan . . . 17
6. Membaca Hasil dan Menulisnya di Skripsi . . . 18
6.1 Tabel yang bisa dimasukkan ke Bab Hasil . . . 18
6.2 Pola yang sering muncul dan artinya . . . 18
6.3 Contoh kalimat analisis . . . 19
6.4 Pertanyaan penguji yang mungkin muncul . . . 19
7. Kesalahan yang Harus Dihindari . . . 19
8. Di Mana Mencarinya di Lab? . . . 20
9. Kamus Istilah . . . 21
10. Referensi yang Disebut . . . 21

1. Sebelum Mulai: Satu Cerita untuk Semua Istilah

Panduan ini ditulis untuk orang yang **belum pernah** belajar statistik atau kecerdasan buatan. Setiap istilah dijelaskan dulu dengan perumpamaan sehari-hari, baru kemudian dengan istilah teknisnya. Di beberapa bagian ada kotak **"Bahasa formal untuk skripsi"** yang berisi kalimat akademis siap pakai.

1.1 Cerita pengawas ujian

Seluruh panduan ini memakai satu cerita. Ingat baik-baik, karena hampir semua istilah akan kembali ke cerita ini.

Ceritanya
Ada **20 siswa** yang ujian. Sebenarnya **5 di antaranya mencontek**, tetapi pengawas tidak tahu siapa. Pengawas **menunjuk 4 siswa** yang ia curigai: **3** memang mencontek (pengawas benar), **1** ternyata jujur (pengawas salah tuduh). Sementara itu, **2** penyontek lainnya **tidak ketahuan**.

Dalam sistem kita, cerita ini diterjemahkan seperti berikut:

Di cerita	Di sistem
Siswa	**Sepasang dokumen** (misalnya tugas Andi dibandingkan dengan tugas Siti)
Mencontek	Pasangan itu **benar-benar plagiat**
Pengawas menunjuk	Sistem **menandai** pasangan itu sebagai plagiat
Pengawas pertama yang cepat	**Tahap 1**: perbandingan otomatis dengan embedding (gratis, cepat)
Pengawas kedua yang teliti tapi mahal	**Tahap 2**: pemeriksaan oleh LLM / AI (Claude atau Gemini)

1.2 Apa yang sebenarnya ingin kita ketahui?

Penelitian ini pada dasarnya ingin tahu **seberapa bagus "pengawas" buatan kita**. Diterjemahkan menjadi lima pertanyaan:

Kode	Pertanyaan dalam bahasa sederhana	Dijawab dengan
RQ1	Seberapa pintar pengawas pertama (Tahap 1) menemukan plagiat?	Precision, recall, F1
RQ2	Cara membandingkan mana yang paling berguna: per kalimat, per paragraf, atau keseluruhan? Apakah menggabungkan ketiganya lebih baik?	Tabel ablation
RQ3	Apakah pengawas kedua (LLM) benar-benar membantu? Berapa biaya yang dihemat karena ada pengawas pertama?	Tahap 1 vs Tahap 1+2, penghematan
RQ4	Jenis contekan apa yang mudah dan sulit ketahuan?	Deteksi per jenis plagiat
RQ5	Seberapa pintar sistem mengenali tulisan buatan AI?	Evaluasi deteksi AI

1.3 Alur pengujian secara singkat

1. **Siapkan "bank soal" yang kunci jawabannya sudah diketahui**, yaitu korpus uji berlabel (Bagian 4).
2. **Uji awal (baseline)** dengan pengaturan bawaan, sebagai titik pembanding.
3. **Coba-coba ukuran potongan teks** (panjang passage).
4. **Coba-coba seberapa mirip dua kalimat baru dianggap kembar** (ambang kalimat).
5. **Pilih porsi tiap cara perbandingan** (bobot lapis).
6. **Pilih nilai batas kecurigaan** (ambang Tahap 2).
7. **Uji lengkap** dengan LLM dan deteksi AI.
8. **Ujian sungguhan**: satu kali, di data yang belum pernah dipakai.
9. **Baca dan tulis hasilnya** (Bagian 6).

> **Kabar baik**
> Langkah 2 sampai 6 tidak memakai LLM, jadi **gratis, cepat, dan hasilnya selalu sama** kalau diulang. LLM baru dipakai di langkah 7 dan 8, setelah semua pengaturan dipilih.

2. Cara Sistem Membandingkan Dua Tulisan

2.1 Embedding: memberi "alamat" pada makna

Komputer tidak mengerti kalimat seperti manusia. Karena itu, setiap potongan teks diubah menjadi deretan angka yang mewakili **maknanya**. Proses ini disebut **embedding**.

> **Perumpamaan**
> Bayangkan sebuah peta. Setiap kalimat diberi **alamat** di peta itu. Kalimat yang maknanya mirip mendapat alamat yang **berdekatan**, walaupun kata-katanya berbeda. Misalnya "Saya lapar" dan "Perut saya keroncongan" letaknya dekat, sedangkan "Harga cabai naik" letaknya jauh.

Cosine similarity adalah ukuran seberapa dekat dua alamat itu. Hasilnya berupa angka, kira-kira dari 0 sampai 1 (secara teknis bisa sampai −1):

Nilai	Artinya kira-kira
0,95 – 1,00	Hampir pasti kalimat yang sama, atau hanya beda sedikit
0,80 – 0,95	Maknanya sangat mirip (sering berupa parafrase)
0,50 – 0,80	Membahas topik atau gagasan serupa
di bawah 0,50	Cenderung berbeda

Contoh nyata dari sistem: dua kalimat parafrase berbahasa Indonesia mendapat 0,944, sedangkan kalimat yang topiknya berbeda mendapat −0,066.

2.2 Kenapa teks harus dipotong-potong?

Model yang dipakai hanya bisa **membaca sekitar 80–100 kata sekali baca** (secara teknis: 128 token). Bagian setelahnya tidak terbaca sama sekali.

> **Perumpamaan**
> Bayangkan membaca buku lewat **lubang intip kecil** yang hanya muat satu paragraf. Untuk membaca seluruh buku, kita harus menggeser lubang itu paragraf demi paragraf. Sistem melakukan hal yang sama.

Karena itu setiap tulisan dipotong menjadi tiga ukuran:

Ukuran	Artinya	Cara dibuat
Kalimat	Satu kalimat	Dipotong di tanda titik, tanya, atau seru. Potongan yang terlalu pendek (di bawah 4 kata, misalnya judul) digabung ke kalimat berikutnya.
Passage	"Paragraf mini": beberapa kalimat berurutan	Kalimat digabung sampai mencapai batas jumlah kata (bawaan 60 kata).
Dokumen	Seluruh tulisan	Gabungan (rata-rata) dari semua passage.

2.3 D, P, dan K: tiga cara membandingkan

Setiap pasangan tulisan dibandingkan dengan **tiga cara**. Di halaman Lab, ketiganya disingkat **D**, **P**, dan **K**.

Singkatan	Nama	Pertanyaan yang dijawab	Perumpamaan
D	Dokumen	Apakah kedua tulisan membahas **topik yang sama**?	Membandingkan judul dan isi buku secara garis besar
P	Passage	Apakah **gagasan per paragrafnya** sama?	Membandingkan isi tiap bab
K	Kalimat	Berapa banyak kalimat yang **kembar** (hampir identik)?	Menghitung halaman yang hasil fotokopi

D (Dokumen): menangkap kesamaan topik

- Nilainya tinggi kalau dua tulisan membahas topik yang sama.
- **Kelemahannya:** di satu kelas, semua mahasiswa mengerjakan **soal yang sama**, sehingga D tinggi untuk hampir semua pasangan walaupun tidak ada yang menyontek. Di korpus contoh, dua esai berbeda yang topiknya sama tetap mendapat D sekitar 0,6.

P (Passage): menangkap gagasan yang sama, termasuk parafrase

- Untuk setiap paragraf mini di tulisan A, sistem mencari paragraf mini yang paling mirip di tulisan B, lalu merata-ratakan hasilnya (dilakukan dari dua arah, A ke B dan B ke A).
- Bagus untuk menangkap parafrase, yaitu gagasan sama dengan kata-kata berbeda.
- **Kelemahannya:** masih bisa cukup tinggi untuk tulisan yang kebetulan membahas poin-poin serupa.

K (Kalimat): menangkap kalimat yang disalin

- Menghitung **berapa persen kalimat** yang punya "kembaran" di tulisan lain.
- Sebuah kalimat dianggap punya kembaran kalau kemiripannya dengan kalimat terdekat di tulisan lain mencapai **ambang kalimat** (bawaan 0,85; dijelaskan di 2.6).

```
Tulisan A: 10 kalimat, 6 punya kembaran di B  ->  6/10 = 0,60
Tulisan B:  8 kalimat, 6 punya kembaran di A  ->  6/8  = 0,75
K = rata-rata keduanya = (0,60 + 0,75) / 2    =  0,675
```

- Sangat bagus untuk menangkap **salin-tempel**.
- **Kelemahannya:** kalau setiap kalimat ditulis ulang (misalnya diparafrasekan oleh AI), K menjadi rendah.

2.4 Bobot lapis: porsi tiap cara dalam nilai akhir

Ketiga nilai (D, P, K) digabung menjadi satu **skor gabungan**. Cara menggabungkannya mirip menghitung **nilai akhir mata kuliah**:

Perumpamaan
Nilai akhir = 20% UTS + 40% UAS + 40% Tugas. Persentase itu adalah **bobot**: seberapa besar pengaruh setiap komponen.

```
Skor gabungan = 20% x D  +  40% x P  +  40% x K       (bobot bawaan 0,2 / 0,4 / 0,4)

Contoh pasangan parafrase:  D = 0,88   P = 0,88   K = 0,50
Skor gabungan = 0,2 x 0,88 + 0,4 x 0,88 + 0,4 x 0,50
              = 0,176 + 0,352 + 0,200 = 0,728
```

D hanya diberi porsi kecil (20%) karena, seperti dijelaskan tadi, D tinggi untuk semua tugas yang soalnya sama.

Jujur di skripsi
Bobot 0,2 / 0,4 / 0,4 adalah **tebakan awal yang masuk akal**, bukan hasil penelitian orang lain. Bobot yang dipakai di skripsi harus dipilih dari data dengan cara di Bagian 5, Langkah 4.

Bahasa formal untuk skripsi
Skor gabungan dihitung sebagai rata-rata berbobot dari skor kemiripan lapis dokumen (D), passage (P), dan kalimat (K): $S = (w_D \cdot D + w_P \cdot P + w_K \cdot K) / (w_D + w_P + w_K)$.

2.5 Ambang batas: nilai batas kecurigaan

Ambang batas adalah **nilai minimal** agar sebuah pasangan dicurigai. Kalau skor gabungannya mencapai ambang, pasangan itu diteruskan ke pengawas kedua (LLM). Kalau di bawah ambang, langsung dianggap aman.

Perumpamaan
Mirip **nilai batas lulus (KKM)**, hanya saja di sini yang mencapai batas justru "dicurigai" dan diperiksa lebih lanjut.

Ambang	Yang terjadi
Rendah (mis. 0,50)	Pengawas pertama lebih curigaan: lebih banyak penyontek tertangkap, tapi lebih banyak juga yang harus diperiksa LLM (lebih mahal).
Tinggi (mis. 0,85)	Pengawas pertama lebih santai: sedikit yang diperiksa LLM (hemat), tapi banyak penyontek lolos.

Hal terpenting
Siswa yang dibiarkan pengawas pertama **tidak pernah diperiksa** pengawas kedua. Jadi pengawas kedua hanya bisa **membebaskan** orang yang salah dicurigai; ia tidak bisa menangkap penyontek yang sudah lolos. Karena itu ambang batas harus dipilih supaya pengawas pertama **jarang meloloskan penyontek**.

2.6 Ambang kalimat: seberapa mirip baru dianggap "kembar"

Ambang kalimat (bawaan 0,85) dipakai saat menghitung K. Dua kalimat dianggap **kembar** kalau kemiripannya mencapai nilai ini.

Perumpamaan
Seperti menentukan kapan dua foto dianggap "foto yang sama". Kalau standarnya terlalu longgar, dua foto pemandangan yang mirip ikut dianggap sama. Kalau terlalu ketat, foto yang hanya diberi filter pun dianggap berbeda.

Ambang kalimat	Yang terjadi
Longgar (0,75)	Kalimat yang sekadar membahas hal serupa ikut dianggap kembar. K naik untuk semua pasangan, termasuk yang tidak menyontek, sehingga lebih banyak salah tuduh.
Sedang (0,85)	Salinan dan parafrase ringan dianggap kembar; kalimat yang hanya setopik biasanya tidak.
Ketat (0,95)	Hanya kalimat yang nyaris sama persis yang dianggap kembar. K hanya menangkap salin-tempel.

Jangan tertukar: **ambang kalimat** bekerja untuk pasangan *kalimat*, sedangkan **ambang batas** (2.5) bekerja untuk pasangan *tulisan*.

2.7 Panjang passage: ukuran "paragraf mini"

Panjang passage (bawaan 60 kata) adalah jumlah kata maksimal dalam satu paragraf mini.

- **Terlalu pendek** (20–30 kata): paragraf mini hanya berisi 1–2 kalimat, sehingga P hampir sama dengan K dan konteks gagasannya hilang.
- **Terlalu panjang** (lebih dari ±80 kata): bisa melebihi kemampuan baca model (lubang intip tadi), sehingga ujungnya tidak terbaca. Satu paragraf juga jadi mencampur beberapa gagasan, sehingga kemiripan yang penting "tenggelam".

- Perkiraan: satu kata bahasa Indonesia ≈ 1,3–1,7 token, jadi 60 kata ≈ 80–100 token, masih di bawah batas 128.

2.8 Pengawas kedua (LLM) dan deteksi tulisan AI

- **Tahap 2:** untuk setiap pasangan yang dicurigai, LLM membaca 5 pasang paragraf yang paling mirip, lalu memutuskan *Periksa manual* (kemungkinan plagiat) atau *Aman*, dan menandai bagian mana yang *salinan langsung* atau *parafrase*.
- **Deteksi AI:** setiap tulisan dinilai sendiri-sendiri. Hasilnya peluang ditulis AI dari 0 sampai 1, dengan kesimpulan: 0,70 ke atas *Kemungkinan AI*, 0,35–0,69 *Campuran*, di bawah 0,35 *Tulisan manusia*.
- Jawaban LLM bisa **sedikit berbeda** kalau dijalankan ulang. Hasil Tahap 1 selalu sama persis.

3. Membaca Nilai Hasil: Precision, Recall, F1, dan Lainnya

Bagian ini memakai cerita pengawas ujian dari Bagian 1.1. Kalau lupa, baca lagi sebentar.

3.1 Empat kemungkinan hasil

Dari cerita pengawas, semua kejadian bisa dikelompokkan menjadi empat:

	Pengawas menunjuk	**Pengawas tidak menunjuk**
Memang mencontek (5)	**Tertangkap: 3** (TP, True Positive)	**Lolos: 2** (FN, False Negative)
Jujur (15)	**Salah tuduh: 1** (FP, False Positive)	**Benar dibiarkan: 14** (TN, True Negative)

Tabel seperti ini disebut **confusion matrix**. Di halaman Lab warnanya: hijau = tertangkap, merah = lolos, kuning = salah tuduh, abu-abu = benar dibiarkan. Singkatan Inggrisnya tidak perlu dihafal; ingat saja arti Indonesianya.

"Siapa yang benar-benar mencontek" dalam sistem kita disebut **label** atau kunci jawaban. Label dibuat otomatis dari kategori dokumen di korpus uji (Bagian 4).

3.2 Precision: "Kalau menunjuk, seberapa sering benar?"

```
Precision = yang tertangkap / semua yang ditunjuk = 3 / 4 = 0,75 (75%)
```

Precision rendah berarti banyak orang jujur yang dituduh. Dalam sistem: banyak mahasiswa yang tidak menyontek ikut dicurigai.

3.3 Recall: "Dari semua yang mencontek, berapa yang ketahuan?"

```
Recall = yang tertangkap / semua penyontek = 3 / 5 = 0,60 (60%)
```

Recall rendah berarti banyak penyontek lolos. Dalam sistem: banyak plagiat tidak terdeteksi.

3.4 Kenapa harus melihat keduanya?

Bayangkan dua pengawas yang ekstrem:

Pengawas	Tindakan	Precision	Recall	Masalahnya
Galak	Menunjuk **semua** 20 siswa	5/20 = 25%	5/5 = 100%	15 orang jujur ikut dituduh
Penakut	Hanya menunjuk 1 siswa yang jelas ketahuan	1/1 = 100%	1/5 = 20%	4 penyontek lolos

Kalau hanya melihat satu angka, keduanya bisa tampak sempurna. Padahal keduanya buruk dengan cara berbeda. Karena itu precision dan recall **selalu dilihat bersama**.

3.5 F1: satu nilai untuk merangkum keduanya

F1 menggabungkan precision dan recall menjadi **satu angka dari 0 sampai 1**. Sifat pentingnya: **F1 hanya tinggi kalau keduanya sama-sama baik**. Kalau salah satu jelek, F1 ikut jatuh.

Pengawas	Precision	Recall	Rata-rata biasa	F1
Pengawas kita	75%	60%	67,5%	**0,67**
Galak	25%	100%	62,5% (kelihatan lumayan)	**0,40** (ketahuan buruk)
Penakut	100%	20%	60% (kelihatan lumayan)	**0,33** (ketahuan buruk)

Rata-rata biasa membuat Pengawas Galak tampak lumayan, padahal ia menuduh 15 orang jujur. F1 tidak bisa "dikelabui" seperti itu. Karena itu **F1 dipakai untuk membandingkan pengaturan mana yang paling baik secara keseluruhan**.

```
F1 = 2 x precision x recall / (precision + recall)
   = 2 x 0,75 x 0,60 / (0,75 + 0,60) = 0,67
```

3.6 Akurasi: hati-hati, bisa menipu

Akurasi adalah persentase keputusan yang benar. Pengawas kita benar pada 3 yang tertangkap + 14 yang dibiarkan = 17 dari 20 = **85%**.

Kenapa akurasi menipu
Bayangkan **Pengawas Tidur** yang tidak menunjuk siapa pun. Ia "benar" pada 15 siswa jujur, jadi akurasinya **15/20 = 75%**. Kedengarannya lumayan, padahal **tidak ada satu pun penyontek yang tertangkap**.
Hal yang sama terjadi pada sistem kita: di korpus contoh hanya 12 dari 91 pasangan yang plagiat. Sistem yang selalu menjawab "bukan plagiat" mendapat akurasi 87%, padahal tidak berguna sama sekali.

Kesimpulannya: **akurasi bukan ukuran utama**. Laporkan precision, recall, dan F1. Akurasi boleh dicantumkan sebagai pelengkap.

3.7 Ringkasan semua ukuran

Ukuran	Pertanyaan yang dijawab	Kalau rendah, artinya...
Precision	Kalau sistem menuduh plagiat, seberapa sering benar?	Mahasiswa jujur ikut dicurigai
Recall	Dari semua plagiat, berapa yang terdeteksi?	Plagiat lolos
F1	Seberapa bagus keseluruhannya?	Salah satunya (atau keduanya) buruk
Akurasi	Berapa persen keputusan benar?	Tidak bisa dipercaya sendirian

Kalau sistem tidak menandai pasangan apa pun, precision tidak bisa dihitung (dibagi nol) dan ditampilkan "—". Di grafik, kondisi ini dihitung F1 = 0 karena tidak ada plagiat yang tertangkap.

Bahasa formal untuk skripsi
Kinerja deteksi diukur dengan precision (proporsi prediksi positif yang benar), recall (proporsi kasus positif yang berhasil terdeteksi), dan F1-score (rata-rata harmonik precision dan recall). Akurasi tidak dijadikan ukuran utama karena distribusi kelas yang tidak seimbang.

3.8 Pengawas pertama dan kedua: mana yang paling penting?

	Tugasnya	Ukuran yang paling penting
Pengawas pertama (Tahap 1)	Cepat dan murah. Menunjuk siapa pun yang mencurigakan. Boleh sesekali salah tuduh, asal tidak meloloskan penyontek.	**Recall**
Pengawas kedua (Tahap 2, LLM)	Teliti tapi mahal. Hanya memeriksa yang ditunjuk pengawas pertama, lalu membebaskan yang ternyata jujur.	**Precision**

3.9 Cross-validation dan "± sd": menguji berkali-kali

Kalau pengaturan dipilih lalu dinilai dengan data yang sama, nilainya jadi terlalu bagus.

Perumpamaan
Seperti membuat soal ujian sendiri lalu mengerjakannya sendiri: nilainya pasti tinggi, tapi tidak membuktikan apa-apa. Masalah ini disebut **overfitting**.

Cross-validation mengatasinya dengan menguji pengawas **5 kali di "kelas" yang berbeda-beda**:

1. Semua pasangan dibagi acak menjadi 5 kelompok. Jumlah plagiat di tiap kelompok diusahakan seimbang.
2. Pengaturan dipilih memakai 4 kelompok, lalu diuji pada 1 kelompok sisanya.
3. Diulang 5 kali sampai setiap kelompok pernah menjadi kelompok penguji.

Pembagian acaknya selalu sama setiap kali dijalankan (memakai "seed 42"), jadi hasilnya bisa diulang persis.

Kolom di tabel ablation	Artinya dalam bahasa sederhana
F1 CV rata-rata ± sd	Rata-rata F1 dari 5 kali uji, dan seberapa naik-turun nilainya. **Ini angka utama untuk dibandingkan dan dilaporkan.**
Precision/Recall CV (gabungan)	Hasil 5 kali uji dijumlahkan dulu, baru dihitung. Lebih stabil kalau datanya sedikit.
F1 terbaik (data penuh)	Nilai kalau soal dibuat dan dikerjakan sendiri. **Terlalu optimis**; hanya sebagai pembanding.
Bobot · ambang terbaik	Pengaturan yang menghasilkan "F1 terbaik" di atas.

Cara membaca "± sd"
"F1 0,73 ± 0,05": rata-ratanya 0,73 dan stabil. Bisa dipercaya.
"F1 0,73 ± 0,40": rata-ratanya 0,73 tapi naik-turunnya besar sekali. Belum bisa dipercaya; biasanya karena datanya terlalu sedikit.
Kalau dua pengaturan selisihnya **lebih kecil dari angka ± itu**, anggap keduanya **sama bagusnya**.

3.10 Tabel "deteksi per jenis plagiat"

Tabel ini menunjukkan **jenis contekan mana yang mudah dan sulit ketahuan**:

- **Salinan langsung, parafrase manual, parafrase oleh AI:** pasangan yang memang plagiat. Kolom "Ditandai" = berapa yang tertangkap. Idealnya 100%.
- **Bukan plagiat (esai independen, teks AI, lainnya):** pasangan yang tidak plagiat. Kolom "Ditandai" di sini = **salah tuduh**. Idealnya 0.
- **Rata-rata D, P, K** menjelaskan **kenapa** sebuah jenis lolos. Contoh dari korpus contoh: parafrase AI punya D 0,87 dan P 0,77 (tinggi), tetapi K hanya 0,27, sehingga skor gabungannya 0,59 dan lolos pada ambang 0,70.
- Pasangan antara dua tulisan turunan (misalnya salinan dengan parafrase AI) dimasukkan ke jenis yang **paling sulit** (parafrase AI).

3.11 Penghematan LLM

Tanpa pengawas pertama, pengawas kedua yang mahal harus memeriksa **semua** pasangan. Penghematannya dihitung begini:

```
Semua pasangan     = N x (N - 1) / 2        (N = jumlah tulisan)
Diteruskan ke LLM  = pasangan dengan skor gabungan >= ambang
Dihemat            = Semua pasangan - Diteruskan ke LLM

Contoh: 14 tulisan -> 91 pasangan. Diteruskan 4 -> dihemat 87 (96%)
```

- Yang dihemat hanya pemeriksaan kemiripan. Deteksi AI tetap 1 kali per tulisan.
- Laporkan penghematan **bersama recall**. Hemat 96% tidak ada artinya kalau banyak plagiat lolos.
- Jumlah pasangan naik sangat cepat: 30 mahasiswa = 435 pasangan, 100 mahasiswa = 4.950 pasangan. Semakin besar kelas, semakin terasa penghematannya.

3.12 Deteksi AI: ketat dan longgar

Versi	Dianggap tulisan AI kalau…	Seperti pengawas yang…
Ketat	Kesimpulannya *Kemungkinan AI* (peluang ≥ 0,70)	Hanya menuduh kalau sangat yakin (precision tinggi, recall rendah)
Longgar	*Kemungkinan AI* atau *Campuran* (peluang ≥ 0,35)	Juga menandai yang meragukan (recall tinggi, precision rendah)

Kunci jawaban AI: tulisan berkategori *Ditulis AI* dan *Parafrase oleh AI*. Tulisan yang gagal dianalisis tidak dihitung.

Dari mana angka 0,70 dan 0,35?
Angka 0,70 dan 0,35 adalah **nilai awal peneliti**, bukan dari studi mana pun. Selain itu, "peluang ditulis AI" adalah angka yang **diucapkan LLM**, dan LLM cenderung terlalu yakin diri saat menyebut angka keyakinan (Xiong dkk., 2024). Jadi 0,85 tidak berarti 85% pasti AI.
Karena itu, ambang dipilih dari data: di halaman hasil eksperimen, bagian **Pengaruh ambang deteksi AI** menampilkan precision, recall, dan F1 untuk ambang 0,10 sampai 0,90, plus form untuk mencoba ambang lain. Semuanya dihitung dari angka yang sudah tersimpan, tanpa memanggil LLM lagi.
Untuk tugas mahasiswa, **utamakan precision** (jangan salah menuduh). Alat pendeteksi AI diketahui sering keliru dan bisa bias terhadap gaya tulisan tertentu (Weber-Wulff dkk., 2023; Liang dkk., 2023). Hasil deteksi AI sebaiknya diperlakukan sebagai **indikasi, bukan bukti**.

Bahasa formal untuk skripsi
Ambang klasifikasi deteksi AI ditentukan secara empiris pada korpus berlabel karena skor probabilitas berasal dari penilaian verbal LLM yang tidak terkalibrasi (Xiong dkk., 2024). Pemilihan ambang mengutamakan precision mengingat risiko salah tuduh pada konteks akademik (Weber-Wulff dkk., 2023; Liang dkk., 2023).

4. Menyiapkan "Bank Soal" (Korpus Uji)

Untuk menilai pengawas, kita butuh ujian yang **kunci jawabannya sudah kita ketahui**: kumpulan tulisan yang kita tahu persis mana yang menyontek. Kumpulan ini disebut **korpus uji berlabel**.

Jangan pakai korpus contoh untuk skripsi
Korpus contoh di Lab seluruhnya ditulis AI, termasuk yang berlabel "asli" dan "parafrase manual". Pakai hanya untuk latihan memakai Lab, **jangan** untuk data skripsi.

4.1 Jenis tulisan dan cara membuatnya

Jenis	Cara membuat	Kunci jawaban
Asli	Esai tulisan manusia, misalnya tugas lama (dengan izin penulisnya) atau esai yang ditulis relawan.	Sumber
Salinan langsung	Salin dari tulisan asli. Variasikan: salin semua, salin separuh, atau sisipkan paragraf sendiri.	Plagiat
Parafrase manual	Relawan (manusia, bukan AI) menulis ulang tulisan asli dengan kata-katanya sendiri.	Plagiat
Parafrase oleh AI	Minta ChatGPT/Gemini/Claude memparafrasekan tulisan asli. Catat nama AI dan perintahnya.	Plagiat + tulisan AI
Independen	Esai lain dari **soal yang sama** tapi ditulis sendiri, tanpa melihat tulisan lain. Ini penguji yang paling penting.	Bukan plagiat
Ditulis AI	Minta AI menulis esai dari soal yang sama, tanpa diberi tulisan asli.	Bukan plagiat + tulisan AI

Di Lab, tulisan turunan (salinan dan parafrase) harus dipilihkan **tulisan sumbernya**. Dari situ sistem otomatis tahu pasangan mana yang plagiat, jadi kamu tidak perlu menandai ratusan pasangan satu per satu.

4.2 Berapa banyak yang dibutuhkan?

- Gunakan **2–3 topik/soal** berbeda, supaya kesimpulan tidak hanya berlaku untuk satu tema.
- Per topik, misalnya: 8–10 tulisan asli, 8–10 independen, turunan (salinan, parafrase manual, parafrase AI) untuk sebagian tulisan asli, dan 3–5 tulisan AI.
- Total **30–60 tulisan per dataset**. Contoh: 40 tulisan sudah menghasilkan 780 pasangan.
- Usahakan ada minimal **20–30 pasangan plagiat**. Dengan hanya 12 (korpus contoh), angka ± bisa sebesar 0,4.
- Panjang tulisan mendekati tugas sebenarnya (sekitar 300–1.000 kata).

4.3 Dua dataset: latihan dan ujian sungguhan

Selama memilih pengaturan, kamu akan melihat hasil puluhan kali, sehingga lama-lama pengaturan "terbiasa" dengan data itu. Supaya angka yang dilaporkan jujur, siapkan **dua kumpulan terpisah**:

Dataset	Seperti...	Dipakai untuk
Pengembangan	Soal latihan / try-out	Mencoba-coba dan memilih pengaturan. Boleh dilihat berkali-kali.
Uji akhir	Ujian sungguhan	Dijalankan **sekali saja** setelah semua pengaturan dikunci. Angka inilah yang dilaporkan.

Contoh pembagian: topik A dan B untuk pengembangan, topik C untuk uji akhir.

4.4 Etika dan catatan

- Minta izin penulis tulisan asli, hapus identitas (nama, NIM), dan jelaskan bahwa tulisannya dipakai untuk penelitian.
- Catat di keterangan dataset: sumber tulisan, siapa yang membuat parafrase, AI dan perintah yang dipakai, serta tanggalnya.
- Simpan salinan korpus di luar sistem sebagai arsip penelitian.

5. Langkah Uji Coba dari Awal

Setiap langkah berisi: **tujuannya**, **apa yang diklik di Lab**, **apa yang dilihat**, dan **cara memilih**. Catat setiap percobaan di lembar catatan (5.10).

5.1 Langkah 0: Cek sistem

1. Masuk sebagai peneliti, lalu buka **Lab Pengujian**.
2. Buka **Uji cepat dua teks**, tempel dua teks yang mirip, lalu klik **Bandingkan**. Kalau muncul angka D, P, dan K, sistem siap.
3. Buat dataset pengembangan, lalu tambahkan tulisan beserta jenis dan sumbernya.
4. Di halaman dataset, periksa angka **pasangan plagiat (label)** sudah sesuai rencana.

5.2 Langkah 1: Uji awal (baseline)

Tujuan	Mendapat titik awal untuk dibandingkan dengan semua percobaan berikutnya.
Klik	Halaman dataset → **Jalankan eksperimen** → beri nama "E1 Baseline". Biarkan semua angka bawaan. **Jangan** centang Tahap 2 dan deteksi AI.
Catat	F1 CV baris "Bobot run" di tabel ablation, recall, dan tabel deteksi per jenis.

5.3 Langkah 2: Mencoba panjang passage

Tujuan	Mencari ukuran paragraf mini yang paling bisa membedakan plagiat dan bukan plagiat.
Klik	Jalankan 4 eksperimen yang **hanya berbeda panjang passage**: **30, 45, 60, 75**. Yang lain biarkan bawaan, tanpa Tahap 2. Beri nama mis. "E2-P30", "E2-P45", dan seterusnya.
Lihat	Di tabel ablation tiap eksperimen: baris **Lapis passage saja** (F1 CV).
Pilih	Yang F1 CV-nya paling tinggi. Kalau selisihnya lebih kecil dari angka ±, pilih **60** (bawaan, aman dari batas baca model).

5.4 Langkah 3: Mencoba ambang kalimat

Tujuan	Mencari standar "kembar" yang membuat K tinggi untuk plagiat tetapi tetap rendah untuk esai independen.
Klik	Dengan panjang passage terpilih, jalankan 5 eksperimen dengan ambang kalimat **0,75; 0,80; 0,85; 0,90; 0,95**, tanpa Tahap 2.
Lihat	Baris **Lapis kalimat saja** di tabel ablation. Di tabel per jenis: rata-rata K untuk salinan (harus mendekati 1) dan untuk esai independen (harus mendekati 0).
Pilih	Yang F1 CV-nya paling tinggi dan K esai independen tetap rendah (mis. di bawah 0,1). Kalau setara, pilih yang lebih tinggi (lebih jarang salah tuduh).

Panjang passage dan ambang kalimat mengubah cara D, P, dan K **dihitung**, jadi setiap nilai butuh eksperimen baru. Sebaliknya, bobot dan ambang batas hanya mengubah cara angka **digabung**, sehingga bisa dicoba langsung tanpa eksperimen baru.

5.5 Langkah 4: Memilih bobot lapis

Tujuan	Menentukan porsi D, P, dan K (menjawab RQ2).
Klik	Buka eksperimen dengan passage dan ambang kalimat terpilih. Tidak perlu eksperimen baru; lihat **tabel ablation**.
Lihat	Enam baris: hanya D, hanya P, hanya K, porsi sama rata, porsi run, dan **bobot hasil optimasi** (sistem mencoba 66 kombinasi porsi secara otomatis).
Pilih	Yang F1 CV-nya paling tinggi. Kalau "optimasi" tidak jauh lebih baik dari "sama rata" (selisihnya kurang dari angka ±), pilih yang lebih sederhana dan jelaskan alasannya.

Kamu juga bisa mencoba porsi apa pun di bagian **Coba bobot & ambang lain**; hasilnya langsung muncul.

5.6 Langkah 5: Memilih ambang batas

Ini keputusan paling penting, karena menentukan berapa plagiat yang bisa tertangkap dan berapa biaya LLM.

1. Tentukan **target**: berapa persen plagiat yang wajib sampai ke pengawas kedua. Misalnya 90% (recall ≥ 0,90).
2. Buka eksperimen dengan bobot terpilih. Di bagian **F1 terhadap ambang**, klik **Tampilkan tabel data**.
3. Lihat kolom **R gabungan** (recall). Cari ambang **paling tinggi** yang recall-nya masih memenuhi target.
4. Cek biayanya: masukkan ambang itu di **Coba bobot & ambang lain**. Tertangkap + salah tuduh = jumlah pasangan yang akan diperiksa LLM.
5. Kalau sistem akan dipakai **tanpa** LLM, pilih saja ambang dengan F1 paling tinggi.

Ambang	Recall	Pasangan ke LLM	Keputusan
0,50	1,00	40	Semua tertangkap, tapi 40 kali panggil LLM
0,55	0,92	18	**Dipilih**: ambang paling tinggi yang recall-nya ≥ 0,90

Ambang	Recall	Pasangan ke LLM	Keputusan
0,60	0,83	10	Recall di bawah target

Angka di tabel ini hanya ilustrasi cara memilih, bukan hasil sungguhan.

5.7 Langkah 6: Uji lengkap

Tujuan	Mengukur seberapa membantu LLM (RQ3) dan seberapa pintar deteksi AI (RQ5).
Klik	Jalankan eksperimen dengan semua pengaturan terpilih, lalu **centang Tahap 2 dan deteksi AI**. Beri nama mis. "E6 Lengkap".
Periksa	Tidak boleh ada **kotak merah "panggilan LLM gagal"**. Kalau muncul (biasanya karena kuota habis), hasil LLM tidak sah. Jalankan ulang setelah kuota pulih.
Lihat	Perbandingan **Tahap 1 vs Tahap 1+2**, deteksi per jenis, penghematan LLM, dan bagian deteksi AI.
Ambang AI	Di bagian **Pengaruh ambang deteksi AI**, pilih ambang dengan precision tinggi (mis. ≥ 0,90) dan recall yang masih wajar. Kalau beberapa ambang sama bagusnya, pilih yang **lebih tinggi** (lebih jarang menuduh). Kunci ambang ini sebelum uji akhir, sama seperti pengaturan lain.
Opsional	Jalankan 2–3 kali untuk melihat apakah jawaban LLM berubah-ubah, lalu laporkan rata-ratanya.

5.8 Langkah 7: Ujian sungguhan (uji akhir)

1. **Kunci** semua pengaturan: panjang passage, ambang kalimat, bobot, dan ambang batas. Jangan diubah lagi setelah melihat hasilnya.
2. Di dataset uji akhir, jalankan **satu** eksperimen lengkap.
3. Angka dari eksperimen inilah yang dilaporkan sebagai kinerja sistem.
4. Klik **Unduh CSV** untuk arsip atau lampiran.

5.9 Langkah 8 (opsional): Membandingkan Claude dan Gemini

Jalankan uji lengkap yang sama dengan AI yang berbeda (ubah pengaturan *.env*, lalu restart FastAPI). Nama AI yang dipakai tercatat di halaman hasil. **Jangan mencampur** hasil dua AI dalam satu angka.

5.10 Lembar catatan percobaan

Isi satu baris setiap kali menjalankan eksperimen (boleh disalin ke Excel). *T2* = Tahap 2 dijalankan, *AI* = deteksi AI dijalankan, *F1 CV* = F1 CV baris "Bobot run" di tabel ablation.

ID	Data	Passage	Amb. kal.	Bobot D/P/K	Ambang	T2	AI	F1 CV	Catatan
E1	Dev	60	0,85	0,2/0,4/0,4	0,70	–	–		Baseline
E2-P30	Dev	30	0,85	0,2/0,4/0,4	0,70	–	–		
E3-K90	Dev	…	0,90	…	…	–	–		

ID	Data	Passage	Amb. kal.	Bobot D/P/K	Ambang	T2	AI	F1 CV	Catatan
E6	Dev	…	…	…	…	ya	ya		Lengkap
E7	Uji	…	…	…	…	ya	ya		Akhir (sekali)

6. Membaca Hasil dan Menulisnya di Skripsi

6.1 Tabel yang bisa dimasukkan ke Bab Hasil

Tabel	Diambil dari	Menjawab
Pengaruh panjang passage	Tabel ablation eksperimen E2-*	Pemilihan pengaturan
Pengaruh ambang kalimat	Tabel ablation eksperimen E3-*	Pemilihan pengaturan
Perbandingan cara (ablation)	Tabel ablation E6 dan E7	RQ2
Tahap 1 vs Tahap 1+2	Confusion matrix E7	RQ1, RQ3
Deteksi per jenis plagiat	Tabel per jenis E7	RQ4
Efisiensi	Ringkasan E7: pasangan, diteruskan, dihemat, durasi, token	RQ3
Deteksi AI ketat/longgar + pengaruh ambang AI	Bagian deteksi AI E7	RQ5
Grafik F1 terhadap ambang	Bagian "F1 terhadap ambang"	Pemilihan ambang

6.2 Pola yang sering muncul dan artinya

Yang terlihat	Artinya	Yang bisa ditulis
Parafrase AI sering lolos; D dan P tinggi tapi K rendah	AI menulis ulang setiap kalimat, sehingga perbandingan per kalimat tidak menangkapnya	Keterbatasan lapis kalimat; cek apakah porsi P lebih besar atau ambang lebih rendah membantu
Banyak salah tuduh pada esai independen	D dan P tinggi karena soalnya sama	Alasan kenapa porsi D kecil; tunjukkan bahwa LLM membebaskan pasangan ini
Precision Tahap 1+2 naik, recall tetap	LLM membebaskan yang salah dicurigai, tapi tidak menangkap yang sudah lolos	Sesuai teori: nilai tambah LLM ada di precision
Bobot hasil optimasi ≈ sama rata	Menggabungkan ketiga cara lebih penting daripada porsi tepatnya	Pilih yang sederhana; laporkan apa adanya
Satu cara saja setara dengan gabungan	Cara lain hampir tidak menambah informasi di data ini	Laporkan jujur; bahas kemungkinan data lain berbeda
Angka ± sangat besar	Data plagiat terlalu sedikit	Tambah data sebelum menarik kesimpulan
Deteksi AI ketat: precision tinggi, recall rendah	Sistem berhati-hati menuduh tulisan AI	Bandingkan dengan versi longgar; bahas sisi etisnya

6.3 Contoh kalimat analisis

Contoh (angka hanya ilustrasi, ganti dengan hasilmu)
"Pada dataset uji, Tahap 1 dengan bobot 0,2/0,4/0,4 dan ambang 0,55 memperoleh recall 0,92 dan precision 0,61 (F1 0,73). Setelah verifikasi LLM, precision meningkat menjadi 0,88 dengan recall tetap 0,92 (F1 0,90), karena LLM menyatakan aman 9 dari 11 pasangan esai independen yang sebelumnya salah ditandai."
"Tahap 1 meneruskan 18 dari 780 pasangan ke LLM, sehingga 762 panggilan (97,7%) tidak diperlukan."
"Parafrase oleh AI merupakan jenis yang paling sulit dideteksi: rata-rata skor lapis kalimat hanya 0,27, jauh di bawah salinan langsung (0,92)."

6.4 Pertanyaan penguji yang mungkin muncul

Pertanyaan	Arah jawaban
Kenapa bobotnya sekian?	Dipilih otomatis dari 66 kombinasi dengan cross-validation pada dataset pengembangan; tunjukkan tabel ablation.
Bagaimana memastikan hasilnya tidak terlalu optimis?	Pengaturan dipilih di dataset pengembangan, lalu dilaporkan dari dataset uji terpisah yang hanya dijalankan sekali.
Apakah LLM benar-benar perlu?	Bandingkan Tahap 1 vs Tahap 1+2: precision naik dan salah tuduh berkurang.
Kenapa tidak memakai akurasi?	Jumlah plagiat jauh lebih sedikit; sistem yang selalu menjawab "bukan" pun berakurasi tinggi (Bagian 3.6).
Dari mana kunci jawabannya?	Dari korpus buatan yang terkendali: setiap tulisan turunan dicatat sumbernya, seperti cara pembuatan korpus PAN.
Apakah hasil LLM bisa berubah?	Ya; tunjukkan hasil beberapa kali jalan bila sempat (Langkah 6, opsional).

7. Kesalahan yang Harus Dihindari

- Memakai **korpus contoh** (buatan AI) sebagai data skripsi.
- Memilih pengaturan dari hasil **dataset uji akhir**, atau menjalankan uji akhir berkali-kali.
- Melaporkan **F1 terbaik (data penuh)** sebagai kinerja sistem. Yang dilaporkan adalah F1 CV atau hasil uji akhir.
- Menjadikan **akurasi** sebagai ukuran utama.
- Mengabaikan **kotak merah "panggilan LLM gagal"**.
- Mencampur hasil **Claude dan Gemini** dalam satu angka.
- Mengklaim pengaturan A lebih baik dari B padahal selisihnya lebih kecil dari angka ±.
- Mengubah isi dataset di tengah rangkaian percobaan. Kalau korpus berubah, buat dataset baru.
- Lupa mencatat pengaturan setiap percobaan (pakai lembar catatan 5.10).

8. Di Mana Mencarinya di Lab?

Yang dicari	Lokasinya
Membuat dataset, korpus contoh, panduan korpus	Lab Pengujian (halaman utama)
Menambah tulisan, jenis, dan sumber	Halaman dataset → panel **Tambah dokumen**
Menjalankan eksperimen	Halaman dataset → panel **Jalankan eksperimen**
Ringkasan, penghematan, durasi, token	Halaman eksperimen → bagian paling atas
Tabel ablation (F1 CV ± sd)	Halaman eksperimen → **Ablation: kontribusi tiap lapis embedding**
Deteksi per jenis plagiat	Halaman eksperimen → **Deteksi per jenis plagiat**
Tahap 1 vs Tahap 1+2	Halaman eksperimen → **Keputusan run**
Grafik dan tabel recall/F1 per ambang	Halaman eksperimen → **F1 terhadap ambang** → Tampilkan tabel data
Mencoba bobot dan ambang lain	Halaman eksperimen → **Coba bobot & ambang lain**
Hasil deteksi AI	Halaman eksperimen → **Deteksi konten AI**
Memilih ambang deteksi AI	Halaman eksperimen → **Pengaruh ambang deteksi AI** → Tabel data & coba ambang lain
Nilai D/P/K setiap pasangan	Halaman eksperimen → **Semua pasangan**, atau **Unduh CSV**
Membandingkan dua teks secara langsung	Menu **Uji cepat dua teks**

9. Kamus Istilah

Istilah	Arti dalam bahasa sederhana
Embedding	Mengubah makna tulisan menjadi deretan angka ("alamat" di peta makna).
Cosine similarity	Seberapa dekat dua alamat makna. Makin mendekati 1, makin mirip.
Token	Potongan kata yang dibaca model. Model ini hanya bisa membaca ±128 token sekali baca.
Passage	"Paragraf mini": beberapa kalimat berurutan, maksimal N kata.
D / P / K	Kemiripan dilihat dari seluruh tulisan / per paragraf mini / per kalimat.
Skor gabungan	Nilai akhir kemiripan, dari D, P, dan K sesuai porsinya.
Bobot lapis	Porsi D, P, dan K dalam skor gabungan (seperti 20% UTS, 40% UAS, 40% tugas).
Ambang batas	Nilai minimal agar sebuah pasangan dicurigai dan diperiksa LLM.
Ambang kalimat	Seberapa mirip dua kalimat baru dianggap "kembar" saat menghitung K.
Tahap 1 / Tahap 2	Pengawas pertama yang cepat (embedding) / pengawas kedua yang teliti (LLM).
Label	Kunci jawaban: plagiat atau bukan, tulisan AI atau manusia.
Tertangkap (TP)	Plagiat yang benar terdeteksi.
Salah tuduh (FP)	Bukan plagiat, tapi dicurigai sistem.
Lolos (FN)	Plagiat yang tidak terdeteksi.
Benar dibiarkan (TN)	Bukan plagiat, dan memang tidak dicurigai.
Precision	Kalau sistem menuduh, seberapa sering benar.
Recall	Dari semua plagiat, berapa yang terdeteksi.
F1	Satu nilai yang hanya tinggi kalau precision dan recall sama-sama baik.
Akurasi	Persentase keputusan benar. Bisa menipu kalau plagiatnya sedikit.
Cross-validation	Menguji 5 kali dengan pembagian data berbeda supaya hasilnya bukan kebetulan.
± sd	Seberapa naik-turun nilai dari 5 kali uji. Makin kecil, makin bisa dipercaya.
Overfitting	Pengaturan terlalu "hafal" data latihan sehingga nilainya terlalu bagus.
Ablation	Mencoba sistem dengan sebagian cara dimatikan, untuk melihat sumbangan tiap cara.
Baseline	Percobaan awal sebagai pembanding.
Deterministik	Selalu memberi hasil sama kalau diulang (Tahap 1 ya, LLM tidak).

10. Referensi yang Disebut

- Liang, W., Yuksekgonul, M., Mao, Y., Wu, E., & Zou, J. (2023). GPT detectors are biased against non-native English writers. *Patterns*.

- Potthast, M., Stein, B., Barrón-Cedeño, A., & Rosso, P. (2010). An evaluation framework for plagiarism detection. *COLING 2010: Posters*, 997–1005.
- Weber-Wulff, D., dkk. (2023). Testing of detection tools for AI-generated text. *International Journal for Educational Integrity, 19*, Art. 26.
- Xiong, M., Hu, Z., Lu, X., Li, Y., Fu, J., He, J., & Hooi, B. (2024). Can LLMs express their uncertainty? An empirical evaluation of confidence elicitation in LLMs. *ICLR 2024*.